

# Binary Response variable Estimation.

· 로지스틱 함수.

$$f(x) = \frac{e^x}{1+e^x} \quad \begin{matrix} -\infty < x < \infty \\ 0 \leq y \leq 1. \end{matrix}$$

실수값을 0과 1사이로 mapping 해줌.

· glm approach

· glm component: random component / linear predictor / link function.

- random component:  $\underline{Y} = (y_1, y_2, \dots, y_n)'$  which is r.v.

$\underline{Y} \sim$  exponential family.

이론: Model Likelihood Equation, Asymptotic Dist, fit Algorithms

이론은 generalized representation,  $S(x) \xrightarrow{D}$  certain dist.  $N(\mu, \sigma^2)$  (ridge, Lasso, lasso reg, logistic...)

- linear predictor: LC of Design Matrix and Parameter.  $\equiv G \cdot B$ .

- link function: link Linear Predictor  $\xrightarrow{G (=X)} R_{mp}$   $\xrightarrow{B} R_{p \times 1}$   
with  $E(Y) (= \mu)$   $g(\widehat{E(Y)}) = XB$ .  $g(\mu) = XB$ .

연립함수의 특징: 단조성 (monotonicity), 미분가능성 (differentiable)

이론: ?

2차 fitting algorithm을

로지스틱 회귀에서  $g(\mu) = \text{logit}(\mu)$

3차기 4차기: Iterative WLS를

$$\text{logit}(\mu) = \ln \frac{\mu}{1-\mu}$$

로지스틱.

로지스틱 함수의 미분  
로지스틱 함수의  $g'(\cdot)$

Applied to logistic regression,

$$g(\mu_i) = X \cdot B \Leftrightarrow \ln \frac{\mu_i}{1-\mu_i} = B_0 + B_1 X_i + \dots + B_p X_i$$

$$\Leftrightarrow \mu_i = \frac{1}{1 + e^{-B \cdot X_i}} = p_i$$

$$E(Y | X_1, \dots, X_n) = P(Y=1 | X_1, \dots, X_n) \cdot Y=1 + P(Y=0 | X_1, \dots, X_n) \cdot Y=0$$

$$= P(Y=1 | X_1, \dots, X_n)$$

$$= \frac{1}{1 + e^{-B \cdot X_i}}$$

# Logit & Probit.

$$\text{logit}(u) = \ln \frac{u}{1-u}.$$

$$\text{probit}(u) = \Phi(u) = P(Z \leq u). \text{ (cdf of standard Normal).}$$

link function이 logit/probit 일때,

$E(Y|X)$  는 각각 logistic regression / probit regression. 가 된다.

$$\frac{1}{1+e^{-\beta \cdot X}}$$

$$\Phi(\beta X)$$

비슷해 보일!

T/C group 이 대조하여 각각 확인!

Logit/Probit 모형은 종속변수 propensity score  $\pi_X$  를 추정하고,

(regression)  
propensity score 값이 0보다 크거나 작지 않는 observation 들을.

matching 하여, T/C group이 비슷한 Covariate 값들을 갖게끔 matching 시켜준다.

이를 통하여 D:D. Causal Inference 를 할 수 있다.

(treatment를 할지는 어떤지 !)

treatment를 할지는  $\gamma(Z)$  을 안다면,

$D = \{1\}$  이거나 soft clustering을 통하여 cluster가 아닌

정확한 클러스터링.

cluster의 중심이 soft 하게 바뀌게 됨 (treat to t+x).

정확한 클러스터링

ex)

동기화 등. 모의 실험  
실험군  
조작

assignment prob에 대한 함수를 얻음  $\rightarrow$  generalized parameters를

최적화 시켜야

maximize assignment prob을  
얻을 필요가 있음.